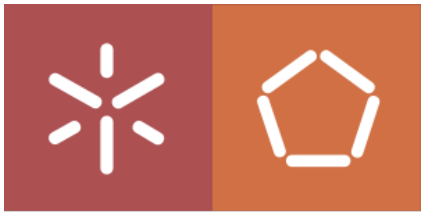

Universidade do Minho
Escola de Engenharia

Laboratórios de Informática III

Trabalho prático – Fase 1

Grupo 60

Alexandre de Oliveira Monsanto, a104358

Maria Inês da Rocha Pinto Gracias Fernandes, a104522

Vasco João Timóteo Gonçalves, a104527

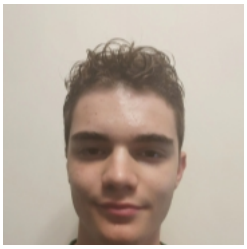

a104358

a104522

a104527

Novembro, 2024

Índice

Introdução

O presente relatório apresentará informações relativas a ambas as fases do Trabalho Prático da Unidade Curricular Laboratórios de Informática III, pertencente ao 2º Ano da Licenciatura em Engenharia Informática da Universidade do Minho, realizada no ano letivo 2024/2025.

O projeto final referido consiste na implementação de uma base de dados em memória, utilizando-se ficheiros *.csv* fornecidos pelos professores, constituídos por dados relativos a um sistema de *streaming* de música (*artists*, *musics*, *users*), sendo o objetivo principal armazená-los e implementar métodos de pesquisa e associações entre estes.

São aplicados neste trabalho conceitos fundamentais como modularidade, encapsulamento, reutilização e abstração de dados.

Concluída a 1ª fase, na qual foi implementado o *parsing* e validação dos dados de entrada, o modo *batch* e as 3 *queries* propostas pela equipa docente, enfrentámos os restantes desafios propostos na 2ª e última fase: conclusão das três *queries* restantes, criação do modo interativo, e testes funcionais e de desempenho.

Ajustes realizados

Seguem-se algumas alterações executadas no desenvolvimento da 2ª fase, tanto por aconselhamento dos docentes durante a 1ª defesa, como para funcionamento ideal do programa com o novo *dataset*, de um tamanho razoavelmente maior ao inicialmente usado. São elas:

- Alteração do nome dos ficheiros que gerem os diversos campos de dados (por exemplo, alteração do nome do ficheiro *musics* para *musicCatalog*), facilitando a leitura do código.

- Restrutura dos ficheiros *parser* (que foi alterado para *program*) e *main* devido a alguns problemas detetados ao enfrentar um *dataset* maior e ao criar os campos *history* e o *album*.

Sistema

A aplicação, através do número de argumentos recebidos, seleciona o seu modo de funcionamento. Nesta fase foi apenas implementado o modo *batch*, sendo apenas este analisado nesta secção.

No início da aplicação, dentro dos catálogos do módulo *database*, são imediatamente criadas todas as estruturas necessárias para armazenar os dados que, posteriormente, serão preenchidas pelos próximos passos.

Através do primeiro argumento (caminho para os ficheiros *.csv* do *dataset*) é populada a base de dados que contém os catálogos de cada entidade. A leitura de dados do ficheiro é realizada através de um *parser* genérico que recebe apontadores para funções que fazem o tratamento, validação e inserção dos dados nos catálogos. Caso a validação dos dados falhe, o *parser* escreve num ficheiro passado como argumento.

Seguidamente, é realizado o *parsing* dos comandos que obtém o índice da *query* a ser chamada, o modo de *output* dos dados e os argumentos da *query*. As *queries* utilizam funções de listagem e obtenção de dados disponibilizadas pelos catálogos.

Através de um módulo de *writing* genérico com modos de *output* tipo *csv* e tabular (*flag* F), com funções que recebem um número variável de argumentos, respetiva formatação e nome dos campos, as *queries* vão escrevendo as "respostas" num *buffer* de ficheiro, transferido para o disco no final da execução do comando.

Após a execução do programa, é feita uma limpeza da memória, eliminando todas as estruturas previamente criadas pelos módulos e, consequentemente, eliminados os dados do *dataset*, evitando *memory leaks*.

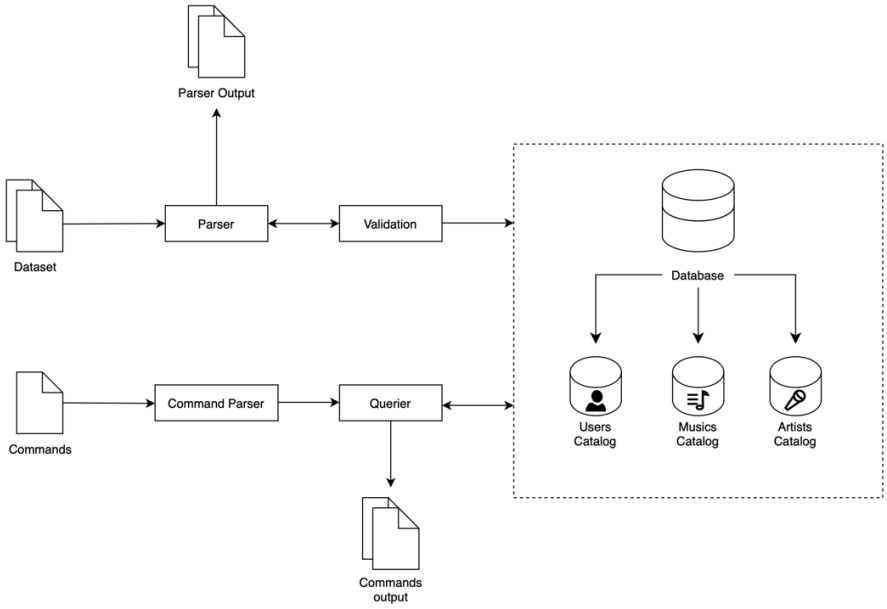

Figura 1 - Arquitetura para a aplicação a desenvolver

Discussão

1. Análise de desempenho

O desempenho do projeto foi avaliado com base nas *queries* realizadas, testando-se o tempo de execução e o consumo de memória nas diferentes máquinas dos membros da equipa. Embora as diferenças de desempenho possam ser observadas devido ao *hardware* variado, os resultados são consistentes com o esperado, dado o uso de algoritmos eficientes, como as *HashTables*.

2. Modularização e encapsulamento

A modularização foi aplicada ao longo do projeto, dividindo-o em várias unidades de código bem definidas e independentes, como módulos para *users*, *musics*, *artists*, *queries* e *utils*. Cada módulo tem uma responsabilidade clara, facilitando a manutenção e a expansão do código. A modularização também ajuda na reutilização do código e na redução da duplicidade.

O encapsulamento foi usado para proteger os dados dentro de cada estrutura, garantindo que as alterações só possam ser feitas por funções específicas, minimizando os efeitos colaterais e a possibilidade de erros. Por exemplo, a criação de novos usuários é feita através de funções como *create_and_store_user*, que asseguram a integridade dos dados.

3. Estruturas de dados

As escolhas de estruturas de dados foram fundamentais para o desempenho e eficiência do sistema. As HashTables foram escolhidas para armazenar todos os catálogos principais, visto que permitem uma procura, inserção e remoção eficientes. O uso de *GPtrArray* da biblioteca *GLib* para armazenar resultados intermédios e ordenações, principalmente usado na resoluções das queries.

Essas escolhas permitiram que o sistema lidasse eficientemente com grandes volumes de dados e consultas, melhorando a capacidade de resposta do sistema. Para a organização de dados como os ids de músicas ou artistas, as listas de *strings* foram adequadas, com validação e *parsing* de dados implementados de forma robusta.

4. *Queries*

4.1. *Query* 1

Na primeira fase, a *Query* 1 permitia listar o resumo de um utilizador com base no seu identificador único. No entanto, na segunda fase, esta *query* foi modificada para permitir listar informações tanto de utilizadores como de artistas, dependendo do id fornecido.

Se o identificador for de um utilizador, a *query* devolve o email, primeiro e último nome, idade e país de origem desse utilizador. Se o identificador for de um artista, a *query* devolve o nome do artista, o tipo (se é individual ou grupo), o número de álbuns a solo e a receita total gerada pelas reproduções das músicas do artista.

A receita total é calculada utilizando as fórmulas apresentadas no enunciado, considerando a taxa por reprodução (*rate_per_stream*) e o número de reproduções de cada música. Para artistas coletivos, a receita reflete apenas as reproduções diretas. Para artistas individuais, a receita inclui não só as suas performances a solo, mas também a sua participação em artistas coletivos.

4.2. *Query* 2

A *Query* 2 permite listar os artistas com a maior discografia, definida pela soma das durações das suas músicas. A *query* aceita um argumento opcional de filtro por país, que, se existir, considera apenas os artistas desse país. A implementação utiliza um *array* de apontadores (*GPtrArray*) para armazenar e processar os artistas, sendo que o tamanho da discografia é calculado individualmente para cada artista.

Cada entrada é formatada com o nome do artista, tipo (individual ou grupo), duração da discografia e país, respeitando o limite imposto pelo argumento ‘N’. A ordenação considera a duração total da discografia e, em caso de empate, o ID do artista (por ordem crescente). Para casos em que o filtro de país exclui alguns artistas, a *query* ajusta automaticamente o número de entradas para completar o top N.

4.3. *Query* 3

A *Query* 3 permite listar os géneros musicais mais populares entre os utilizadores de uma faixa etária específica, definida pelos valores mínimo e máximo de idade fornecidos como argumento. A popularidade de um género é determinada com base no número total de *likes* que músicas desse género receberam de utilizadores dentro da faixa etária especificada.

A implementação começa por validar os argumentos fornecidos, garantindo que as idades mínima e máxima foram corretamente especificadas. Depois disso, utiliza-se o catálogo de utilizadores para identificar os utilizadores que se encontram na faixa etária especificada e as músicas que esses utilizadores gostaram. No fim, processa-se a contagem de *likes* para cada género, utilizando o catálogo de músicas. Os resultados são ordenados por número total de *likes* em ordem decrescente e, em caso de empate, por ordem alfabética do nome do género.

5. Resultados obtidos

Os resultados obtidos nos testes são coerentes com as expectativas, dado que os algoritmos e estruturas de dados utilizadas (*HashTables*, *arrays* dinâmicos e listas de *strings*) são conhecidos pela sua eficiência em situações de grande volume de dados. A modularização e encapsulamento também desempenham um papel importante na redução da complexidade do código e na facilidade de manutenção, sem afetar o desempenho geral do sistema. Em suma, as escolhas técnicas feitas garantiram um equilíbrio entre eficiência e clareza do código.

Conclusão

O trabalho desenvolvido na primeira fase satisfez, de forma geral, os requisitos pedidos. Este projeto foi desenvolvido com o objetivo de ser o mais eficiente e rápido possível, tentando sempre cumprir as regras de encapsulamento e modularidade.

O grande desafio na primeira fase deste projeto foi a programação à larga escala, com base numa grande quantidade de dados disponíveis, sendo imperativo trabalhar com estruturas de dados e algoritmos que se desenvolvessem tanto em complexidade como em eficiência para que pudéssemos concretizar os objetivos. Isto obrigou-nos a explorar e a conhecer uma nova API (GLib) e, consequentemente, ter em consideração os métodos mais eficientes para cada caso. A escolha de estruturas de dados como *HashTables* garantiu-nos que as consultas possam ser feitas de forma rápida e eficaz.

Na segunda fase, foram efetuadas algumas correções ao projeto inicial, tanto por aconselhamento dos docentes durante a 1ª defesa, como para funcionamento ideal do programa com o novo *dataset*, de um tamanho razoavelmente maior ao inicialmente usado.

Para além disto, cumprimos com as alterações necessárias à realização da *Query* 1 relativamente à primeira fase e sucedemos na implementação da *Query* 3.

Nesta fase, o código desenvolvido nos ficheiros de interface (*.h*) está devidamente documentado, seguindo o estilo de documentação da ferramenta *doxygen* e cumprindo todos os requisitos propostos pelo enunciado para este ponto.

Algumas dificuldades que fomos enfrentando ao longo da realização do projeto (em ambas as fases) foram a resolução de *memory leaks*, nem sempre óbvias, e a contínua adaptação de estruturas de dados ao longo da criação das *queries*. Uma outra dificulade foi a necessidade de manter um forte encapsulamento enquanto procurávamos otimizar o desempenho das *queries*, o que acabou por ser um grande desafio de equilíbrio, onde, por vezes, a solução mais rápida não era a que preservava o encapsulamento.

Embora não tenhamos cumprido com todos os requisitos propostos para esta segunda e última fase do projeto e sabendo que há sempre margem para melhorias no futuro, sentimo-nos satisfeitos com o trabalho final.